工作文件**24-038**

开源软件的价值

曼努埃尔·霍夫

曼、弗兰克·纳格

尔、周亚诺

Harvard Business School

开源软件的价值

曼努埃尔·霍夫曼
哈佛商学院

弗兰克·纳格尔
哈佛商学院

周亚诺
多伦多大学

工作文件24-038

版权所有 © 2024 曼努埃尔·霍夫曼、弗兰克·纳格尔和周亚诺。

工作论文目前仍处于草案阶段。本工作论文仅用于征求意见和讨论之目的，未经版权所有者许可不得复制。工作论文副本可向作者索取。

作者衷心感谢Linux基金会提供的资金与行政支持，若无此支持，人口普查数据将无法获取。我们高度赞赏哈佛商学院研究计算服务部、哈佛创新科学实验室、Linux基金会以及软件组成分析数据提供方Snyk、Synopsys网络安全研究中心和fossa所提供的支持。感谢Tianli Li和Misha Bouzinier提供的卓越研究协助。同时，我们亦感谢软件开发者Boris Martinovic，以及微软的Rich Lander和Scott Hanselman对.NET生态系统的深刻见解。我们在哈佛商学院价值观与估值会议、哈佛商学院D3研究日以及2023年管理学院会议上，收到了与会者的宝贵反馈。

本研究的部分资金由哈佛商学院提供。

开源软件的价值

曼努埃尔·霍夫曼[a]　　弗兰克·纳格尔[b]　　周亚诺[c]

此版本：2024年1月1日

摘要

非货币性（免费）产品的价值本质上难以评估。开源软件（OSS）就是一个典型的例子——这种全球性的公共产品在经济中发挥着关键作用，也是当今大多数技术的基础。然而，由于开源软件的非货币属性以及缺乏集中的使用追踪机制，其价值难以量化，因此在经济指标中基本未被纳入考量。尽管先前研究已估算出重新开发这类软件的供给端成本，但数据匮乏阻碍了对开源软件所创造的更大规模需求端（使用）价值的评估。为此，为全面理解广泛使用的开源软件的经济与社会价值，我们利用来自两个互补来源的独特全球数据，这些数据记录了全球数百万企业的开源软件使用情况。首先，我们通过计算重新开发最广泛使用的开源软件所需的成本来估算供给端价值；随后，基于每家使用该软件的企业若开源软件不存在时需自行开发软件所产生的替代价值，计算出需求端价值。我们估算，广泛使用的开源软件（OSS）的供给侧价值为41.5亿美元，而需求侧价值则高达8.8万亿美元。研究发现，若没有开源软件，企业用于软件的研发支出将比当前高出3.5倍。样本中排名前六的编程语言贡献了开源软件需求侧价值的84%；此外，仅5%的开源软件开发者就创造了96%的需求侧价值。

*JEL 分类：*H4；O3；J0
*关键词：*开源软件，全球公共产品

致谢：作者衷心感谢Linux基金会提供的资金与行政支持，若无此支持，人口普查数据将无法获取。我们高度赞赏哈佛商学院研究计算服务部、哈佛创新科学实验室、Linux基金会以及软件组成分析数据提供方Snyk、Synopsys网络安全研究中心和fossa所提供的支持。同时，感谢Tianli Li和Misha Bouzinier在研究工作中给予的卓越协助。我们还要感谢软件开发者鲍里斯·马丁诺维奇，以及微软的里奇·兰德和斯科特·汉塞尔曼，感谢他们对.NET生态系统的深刻见解。我们还收到了来自哈佛商学院价值观与估值会议、哈佛商学院D[3]研究日以及2023年管理学院会议与会者的宝贵反馈。

[a] 哈佛商学院，哈佛大学，地址：马萨诸塞州奥尔斯顿市西大道150号6.220室，邮编：02134；电子邮件：mhoffmann@hbs.edu。
[b] 哈佛商学院，哈佛大学，摩根213室，Soldiers Field，波士顿，马萨诸塞州，02134，电子邮件：fnagle@hbs.edu。
[c] 多伦多大学罗特曼管理学院，地址：加拿大安大略省多伦多市圣乔治街105号，邮编：M5S 3E6；电子邮件：yanuo.zhou@rotman.utoronto.ca。

1. 引言

2011年，风险投资家马克·安德森曾提出著名论断："软件正在吞噬整个世界"（Andreessen，2011），这一观点如今几乎无人质疑。近期，风险投资家约瑟夫·杰克斯更指出："开源软件吞噬软件的速度，比软件吞噬世界的速度还要快"（Jacks，2022）。其他最新研究也得出了相似结论：开源软件（OSS）——其源代码公开供他人检查、使用和修改，通常以去中心化方式开发并免费分发——已存在于96%的代码库中（Synopsys，2023）；部分商业软件中高达99.9%的代码均为免费开源软件（Musseau 等，2022）。尽管开源软件早期常借鉴现有专有软件的功能，但如今它已涵盖人工智能（AI）、量子计算、大数据及数据分析等多个领域的尖端技术。然而，尽管开源软件对所有软件（进而对整个经济）的重要性日益凸显，其实际影响仍难以准确衡量。传统上，为了衡量某种商品或服务所创造的价值，经济学家会将价格（p）乘以销售数量（q）。然而，在开源软件（OSS）中，p通常为零，因为源代码是公开可用的；而q则因对代码复制和重用方式的限制有限而难以确定。例如，如果一家公司从公共代码仓库下载了一段开源软件代码，它可能在内部（合法地）复制数千次，然后与供应商或客户共享（同样合法），因此公开的下载数据并不充分。尽管近期一些研究试图估算p的价值（下文将讨论），但用于估算q的数据要么缺失，要么仅适用于少数几个开源软件包，难以处理。本文利用来自多个来源的新收集数据，旨在同时估算p和q，并借此阐明一个核心问题：开源软件的价值究竟有多大？

理解开源软件（OSS）的价值至关重要，这不仅源于其在经济中的重要作用，更因为它堪称数百年来"公地"这一古老经济概念最成功且最具影响力的现代实践案例——而这一概念本身正面临着所谓的"公地悲剧"。该概念可追溯至公元前4世纪哲学家亚里士多德的论述："为大多数人所共有之物，往往得到最少的照料；人们最关注属于自己的东西，而对公共财产则漠不关心。"（Aristotle，1981）。威廉·福斯特·劳埃德（1833）在现代经济思想中重新提出了这一观点，并以用于牲畜放牧的共享土地为例进行了阐释。

众多牧牛人各自都有过度利用公共资源的动机。加勒特·哈丁（1968）在撰写题为《公地悲剧》的文章时，将这一概念引入了更广泛的学术视野。在此基础上，埃莉诺·奥斯特罗姆因其研究荣获诺贝尔奖——她的研究揭示了通过社区协作避免“公地悲剧”的途径，而无需依赖政府强制立法来管理和保护公共资源（Ostrom 1990）。共享放牧地与共享数字基础设施之间的相似性显而易见：公共牧场可供放牧牲畜、进而养活人类，这对农业经济至关重要；而无需重复编写他人已编写的代码，正是现代经济的关键所在。此外，在这两种情境下，尽管人们深知草地和代码都是经济的重要投入要素，但衡量其实际价值却十分困难。正如著名数学家兼物理学家开尔文勋爵所言：“无法测量的，就无法改进。”“如果无法持续改进和维护这些公共资源，它们可能会因过度使用而崩溃——尽管其成功本身反而会成为压垮它们的重负，但相关投入却严重不足（Lifshitz-Assaf and Nagle，2021）。因此，衡量开源软件（OSS）创造的价值，对于数字经济及其上建立的整个经济体系的未来健康发展至关重要。”

值得注意的是，近期多项研究虽试图解决这些测量难题，但仍未能全面反映开源软件（OSS）使用的广度与深度——这正是本文旨在填补的空白。例如，研究人员通过采用创新方法估算现有开源软件的劳动替代价值：2019年美国开发的开源软件价值达380亿美元（Robbins 等，2021），欧盟开发的开源软件价值为10亿欧元（Blind 等，2021），具体方法是估算重写现有开源软件所需的人力成本。这些研究在估算若所有现有开源软件明日消失所需替代成本方面成效显著。然而，所得估算结果基于两个关键假设。首先，从使用角度来看，所有开源软件（OSS）具有同等价值；其次，OSS的概念依然存在，社会只需重写一次代码即可解决前述p值缺失的问题，但无法解决q值缺失的问题。在完全不存在OSS的世界中，每款开源软件无需仅由一家企业重写一次，而是需要所有使用该软件的企业共同重写（前提是企业可在其内部自由共享该软件）。其他研究（Greenstein and Nagle，2014； MurcianoGoroff，Zhuo，and Greenstein，2021）对此假设进行了更深入探讨，尽管视角较为局限。

这两项研究均仅聚焦于Web服务器（这类服务器面向互联网公众开放，因此易于量化）。通过采用不同方法，两项研究均针对同一类软件测量了q指标，并基于企业提供的闭源替代品价格，运用商品替代价值法推算了p。利用美国数据得出的估算结果显示：2012年开源软件Apache Web Server的价值为20亿美元（Greenstein and Nagle，2014）；而到2018年，Apache与日益流行的开源Web服务器nginx的总价值已达45亿美元（Murciano-Goroff et al.，2021）。尽管Web服务器是开源软件生态系统的重要组成部分，但其占比却很小。我们旨在在此前研究的重要成果基础上，从广度和深度两方面展开深入分析，以构建更全面的开源软件价值评估体系。

为了从广度和深度两方面评估开源软件（OSS）的价值，我们采用了两个主要数据来源的数据，这些数据使我们能够深入了解全球数万家企业所使用的开源软件。首个数据源是“自由及开源软件——应用库第二次普查”（Nagle 等人，2022）。该普查项目通过与多家软件成分分析（SCA）公司合作，编制了各类最广泛使用的开源软件清单。SCA公司负责扫描企业代码库，确保其未违反任何开源软件许可证，并借此追踪客户及所开发产品中使用的全部开源软件代码。普查项目整合了多家SCA提供的数据，基于数百万个开源软件使用观测数据，构建了涵盖数万家企业的开源软件使用情况数据集。第二个数据源是BuiltWith数据集，我们利用对近九百万个网站的扫描结果，识别这些网站所采用的基础技术（包括开源软件库）。BuiltWith数据已被多项学术研究采用（DeStefano & Timmis 2023；Dushnitsky & Stroube 2021；Koning等人，2022），但据我们所知，这是首个专门聚焦开源软件使用情况的研究数据集。Census II数据与BuiltWith数据具有互补性：前者侧重于企业销售软件中内置的开源软件（OSS），而后者则关注企业网站中集成的开源软件，从而降低了在两个数据集中重复计算观测值的可能性。总体而言，这两个数据集的结合构成了迄今为止最完整的开源软件使用情况（q）测量结果。此外，通过聚焦于被企业广泛部署和使用的开源软件，而非考虑开源软件仓库中的所有项目，我们改进了先前研究的方法论——降低了因某些项目虽标榜为公开可用开源软件但实际上未被实际使用而导致测量误差的可能性。若未考虑这一点.....

测量误差会导致对OSS实际价值的高估，因为广泛使用的项目将与完全未使用的项目采用相同的估值方法。

为估算p，我们遵循上述文献方法，采用劳动力替代价值进行计算。首先，通过统计特定开源软件包中的代码行数，并应用构建成本模型II（Boehm，1984； Boehm 等，2009，亦称 COCOMO II）来估算从头编写该代码所需的人工小时数，从而计算出单个企业重新开发该软件包所需的人力成本。随后，利用Salary Expert提供的全球薪资数据，准确估算出若该开源软件不存在时企业需承担的劳动力成本。这些成本可与前述开源软件包层面的q值相结合，最终得出供需双方所有开源软件的综合价值。

如果我们作为一个社会决定在供应端重新开发所有广泛使用的开源软件（OSS），我们得出的数值范围在12.2亿美元至62.2亿美元之间。然而，若考虑开源软件（OSS）的实际使用情况，其需求端价值将高出数个数量级，范围介于2.59万亿美元至13.18万亿美元之间——前提是每家使用OSS软件包的企业都必须从零开始重新开发该软件（例如，OSS的概念当时尚未存在）。我们发现，不同编程语言、内部开发工作与对外开发工作所产生的OSS价值存在显著差异。此外，程序员对价值贡献的差异也十分明显：仅5%的程序员就贡献了供需双方创造总价值的90%以上。目前我们使用的数据堪称衡量企业使用OSS所创造价值最全面的资料来源。但需注意的是，与所有研究项目一样，现有证据并不完整；我们认为实际价值可能被低估，因为我们的数据未涵盖操作系统——这一OSS领域中被大幅遗漏的重要类别。

本研究对学术文献、实践工作者及政策制定者作出了四项重要贡献。首先，本研究首次全面估算了迄今为止广泛使用的开源软件（OSS）的价值，不仅考虑了开源软件的供给端因素（即开发成本），还以前所未有的规模涵盖了使用/需求端的影响。以往对开源软件价值的评估要么过于笼统（仅估算大量开源软件的供给端成本），要么过于单一（仅评估某一特定类型开源软件的价值）；而本研究通过运用独特的数据集，同时实现了这两点，从而更深入地理解了开源软件应用的广度与深度。此外，本研究并未衡量所有开源软件的价值，而是重点关注企业实际使用的开源软件所产生的价值。

本研究旨在明确开源软件（OSS）在产品开发与网站构建中的实际应用，从而减少那些无法准确统计生产过程中实际使用开源软件类型的研究中的测量误差。该成果基于并拓展了多项重要研究（如Blind等人，2021；Greenstein与Nagle，2014；Murciano-Goroff等人，2021；Robbins等人，2021），这些研究致力于揭示这一对现代经济贡献巨大的关键资源的价值——尽管其实际贡献难以量化。通过这项研究，我们为关于信息技术对生产率影响的长期学术讨论（Brynjolfsson，1993； Brynjolfsson 与 Hitt，1996； Nagle，2019a；Solow，1987）——即所谓的“生产率悖论”（即IT投资对生产率统计数据的影响有限）——提供了新的见解。这一争论已延伸至人工智能发展的新兴领域（Brynjolfsson、Rock与Syverson，2018）。我们的研究通过揭示开源软件存在的巨大社会层面成本节约效应（进而提升生产率），为这一学术讨论作出了重要贡献。

其次，我们的研究通过揭示与开源软件（OSS）投资相关的新型数据来源，为无形资本研究带来了方法论上的突破。先前研究表明，无形资本在经济增长（Corrado、Hulten和Sichel，2009）及企业价值（Peters 和 Taylor，2017）中日益发挥重要作用，但其价值往往未被充分量化或被错误归因（Eisfeldt 和 Papanikolaou，2014）。此外，我们展示了如何利用这些数据来源来准确理解企业实际进行的软件投资，以及若无开源软件存在时企业本应进行的投资规模。这一发现具有重要价值，因为软件投资已成为推动创新（Branstetter、Drev和Kwon，2019）与企业绩效（Krishnan 等，2000）的关键无形资本类型。

第三，我们的研究结果有助于帮助企业及管理者认识到开源软件（OSS）对其生产活动的重要性，并有力支持了以下观点：开源软件的使用者不应仅享受免费资源，还应积极参与开源软件的创建与维护（例如：Henkel，2008； Nagle，2018）。此类贡献仅占企业若没有开源软件（OSS）所需成本的一小部分，而OSS用户的积极参与对其所使用的开源软件的维护工作，对于开源软件生态系统的健康与未来发展至关重要（Lifshitz-Assaf and Nagle，2021； Zhang et al.，2019）。

第四，也是最后一点，我们的研究有助于为政策制定者提供参考——这些政策制定者近期已开始认识到开源软件（OSS）对经济日益增长的重要性，并已采取行动支持相关生态系统（欧盟委员会，2020年；第14028号行政命令，2021年）。然而，这些努力大

多集中在保护现有的开源软件生态系统上，这一点固然至关重要，但.....

我们的研究虽未深入到支持创建新型开源软件（OSS）的程度，但其成果有助于揭示开源软件对整体经济的重要性，并为呼吁社会加强对这一关键资源的支持提供了有力依据。研究还表明，开源软件创造的大部分价值实际上源自少数贡献者。尽管长期以来人们已认识到少数开源贡献者承担了主要工作，但我们获得了新的见解：对于广泛使用的开源项目而言，这一现象尤为显著；社会对这些贡献者的支持对于开源软件乃至整个经济的未来成功至关重要。

本文其余部分结构安排如下：第2节阐述了实证研究背景与数据；第3节讨论了研究方法，包括测量过程中遇到的挑战；第4节对开源软件的价值进行了评估；第5节为全文总结。

2. 经验背景与数据

尽管自由开源软件的概念自20世纪50年代便已存在，但直到20世纪80年代才因理查德·斯托曼的努力及其发起的GNU项目和自由软件基金会（Maracke，2019）而广受欢迎。然而，正是在20世纪90年代，随着 Linus Torvalds 发布Linux内核——这一如今已被广泛采用的开源操作系统（OSS）（Tozzi，2016），开源软件才真正蓬勃发展起来。如今，开源软件被视为数字经济的关键基石，被软件开发者广泛应用于从手机、汽车、冰箱到尖端人工智能等各个领域（Lifshitz-Assaf and Nagle，2021）。

我们采用两个互补的主要数据源来估算开源软件（OSS）的价值。第一个数据源是面向内部的“人口普查”数据集，它有助于我们识别企业开发的产品中所使用的开源软件代码；第二个数据集是面向外部的“BuiltWith”数据集，它使我们能够识别消费者通过企业网站直接使用的开源软件代码。由于这两个数据集中的原始数据仅包含软件包名称、版本号和包管理器名称，而不包含任何源代码相关信息，我们首先获取了每个软件包的公开代码仓库，其中包含软件包级别的详细信息，如代码行数及所使用的编程语言。有人可能会担心，由于使用了两个独立的数据集，会导致价值计算出现重复计算的情况。然而，人口普查数据与BuiltWith样本数据之间的重叠范围非常有限：两个数据集中仅有18个软件包是共同存在的。此外，重复计数的问题也不太可能成为问题，因为这两个数据集反映了开源软件使用的不同维度：人口普查数据记录的是面向内部使用的打包软件，而BuiltWith数

据则记录了面向外部网站的软件使用情况。最后，作为补充说明.....

在数据集构建过程中，我们采用了GHTorrent——这是GitHub（全球最受欢迎的开源软件托管平台）上所有开源软件相关活动的详细历史记录，也是开源软件研究领域广泛使用的数据来源（例如：Burton等人，2017；Conti、Peukert和Roche，2023；Fackler、Hofmann和Laurentsyeva，2023；Kim，2020；Tang、Wang和Tong，2023）。这些详尽的历史数据使我们能够更深入地理解：通过更准确地掌握各开源软件开发者贡献的分布情况，可以更有效地揭示开源软件价值的创造机制。下文将详细阐述这三个数据源的具体内容及其数据处理方法。

Census项目。《自由与 Open Source 软件 The Census II》（以下简称Census）由 Linux Foundation 与哈佛大学 Innovation Science 实验室联合开展（Nagle 等人，2022）。[1]该项目通过整合三家主要软件构成分析（SCA）公司的数据而成，这些公司拥有遍布全球的数千名客户。SCA机构受委托扫描客户的代码库，收集其专有软件中嵌入的开源软件（OSS）使用情况，以确保客户未违反任何开源软件许可协议。[2]这种情况通常发生在与并购相关的尽职调查过程中。与其他来自公开来源的开源软件需求指标（如软件包下载次数和代码变更量）不同，该数据的收集方式确保我们能够准确掌握企业内部开源软件的使用规模与类型。此外，它还能帮助我们追踪每个软件包所依赖的组件，从而观察到通常隐藏且难以获取的间接开源软件使用情况。[3]结果显示，在2020日历年度（2020年1月1日至12月31日）期间，SCA客户企业开发的产品中使用了超过270万个开源软件包实例。[4]

Census项目基于libraries.io的命名系统对软件包名称进行了标准化——该网站由Tidelift维护，广泛使用，收录了超过800万个开源软件包的信息。Census项目重点关注使用量排名前2000的软件包。

---

[1] 数据收集与汇总的具体方法详见 Nagle 等人（2022年）发布的普查报告。

[2] 开源软件（OSS）的使用许可差异显著：部分许可极为宽松，允许代码以任何形式重用——包括用于商业用途的专有代码；而另一些许可则规定，只有当最终生成的代码采用相同的开源软件许可（即“左版”许可）发布时，才允许重用。关于开源软件许可的详细论述可参阅 Lerner 与 Tirole（2005）以及 Almeida 等人（2017）的研究。

[3] 间接使用的开源软件（OSS）需通过依赖关系分析来捕捉，这对于准确评估企业所依赖的开源软件的整体范围至关重要。例如，如果企业的专有代码调用了开源软件包A，而该软件包A又调用了软件包B，那么仅查看直接调用关系就会忽略软件包B是企业专有代码不可或缺的构建模块这一事实。

[4] 《人口普查》将OSS软件包定义为“可由包管理器安装和管理的软件单元”，并将包管理器定义为“能够自动化软件包安装及管理流程的软件”（Nagle 等人，2022）。

本研究基于三家最知名的SCA供应商提供的数据，旨在识别使用最广泛的开源软件（OSS），而非关注使用分布中的长尾部分。因此，使用记录不足五次的软件包被排除在外。由于用JavaScript编程语言编写、通常托管在Node Package Manager（NPM）上的软件包通常体积更小（代码行数更少），因此其使用频率往往更高（因为开发者需要集成大量小型软件包而非少数大型软件包）。为此，本次统计专门选取了 NPM 平台上使用量最高的1000个软件包，以及非 NPM 托管平台上使用量最高的1000个软件包。

该最终数据集涵盖了人口普查原始数据中观测到的开源软件（OSS）总使用量的70%。[5]对于人口普查中的这2000个OSS包，我们识别了其在GitHub（开源软件最广泛使用的托管平台）上维护的原始代码。[6]我们首先尝试通过 libraries.io 获取每个包在GitHub仓库的统一资源定位符（URL），通过这种方法成功将1,657个包与对应的仓库进行了匹配。[7]对于没有对应仓库的URL，我们大致按照Singh（2020）的方法进行了Google搜索。具体而言，对于每个未匹配的软件包，我们使用Google API搜索软件包名称和“GitHub仓库”，并将搜索结果中首个GitHub仓库URL视为最匹配的仓库地址。[8]这使得另有174个软件包成功匹配到对应的仓库。最后，我们手动搜索了剩余169个软件包的URL以确定其相关仓库。整个过程最终使2,000个Census软件包中的1,840个成功匹配到包含原始源代码的代码仓库。未匹配的软件包被判定为已从GitHub下架或转为专有软件（因此原始源代码已无法获取），因此手动搜索使我们能够排除这些情况。

---

[5] 在长尾使用分布中，构成完整人口普查数据剩余30%的各类数据包未被纳入最终报告，因此无法被纳入我们的分析。

[6] GitHub是一个托管与协作平台，贡献者可通过该平台协调开源软件（OSS）项目的开发与发布。自2008年成立以来，GitHub已发展成为全球最大的开源软件开发枢纽。截至2023年1月，GitHub拥有超过3.7亿个代码仓库和1亿多名开发者。除个人用户外，众多私营企业也积极使用该平台，其中包括微软（2018年收购GitHub）、Facebook、Google以及众多其他大小企业。

[7] 我们尝试访问所有作为完整性检查而获取的仓库URL，以确认其功能正常。对于在GitHub上无法访问的仓库，我们手动找到了正确的URL。

[8] 作为稳健性验证，我们随机选取了50条通过Google搜索方法获得的软件包存储库匹配结果，并进行了人工核查。所有匹配结果均经人工确认无误，这为自动化匹配方法提供了额外的支持依据。

这160个未匹配的样本包（占人口普查2000人样本量的不足8%）经我们的分析证实具有高度可靠性。

BuiltWith。BuiltWith 数据涵盖了全球所有公共网站的扫描结果，并识别了它们所使用的技术。与侧重于开源软件（OSS）使用的面向内向的 Census 数据不同，BuiltWith 数据对企业和机构网站中专有软件与开源软件的使用情况进行了统一扫描，未作明确区分。为在 BuiltWith 中区分开源软件与专有软件，我们选取了技术类别中包含“JavaScript 及其库”的开源网页开发软件子集——该子集对应 Census 数据中的 NPM OSS 类别，共生成 778 个观测值。选择此抽样方法基于两个原因：首先，该分类由 BuiltWith 自定义，我们将其作为开源软件的替代指标，以将其与商业软件区分开来；其次，JavaScript 作为构建网站的核心技术之一，在 GitHub 上的使用量位居全球首位（GitHub，2022），因此能从需求侧视角捕捉最重要的开源软件。本次扫描覆盖了 880 万个独立网站及 72.2020年1月1日至11月16日期间，共收集到800万条关于开源软件（OSS）使用的对应观测数据。为进一步确保准确衡量私营部门产生的开源软件使用价值，我们将BuiltWith平台中JavaScript相关开源软件的采用领域，与Orbis、Compustat和PitchBook三大常用企业活动数据库中记录的企业网站进行了匹配——这些数据库收录了全球注册企业的信息。通过这种匹配机制，我们确保了非商业网站（例如个人个人网站）使用的开源软件被排除在分析之外。最终匹配率达到38.6%，对应约340万家不同企业的网站。

对于BuiltWith的数据，我们无法采用最初用于人口普查的方法（即使用libraries.io来辅助识别仓库URL），因为BuiltWith仅提供了与软件包相关联的技术名称，而未包含其他信息（例如软件包名称及包管理器名称）。[9]因此，我们首先采用前述的谷歌搜索方法，最终匹配出695个软件包对应的仓库。随后，我们手动检索了 Github 上剩余 83 个未匹配软件包的 URL，最终新增了 46 个软件包。总体而言，针对 BuiltWith 数据集，我们成功识别出 778 个软件包中的 741 个。

[9] 由于软件包及其管理器名称缺失，无法通过libraries.io实现精确匹配。技术名称是面向客户的产品名称，其技术性和精确度通常低于内部开发用途的软件包名称。因此，在 libraries.io 搜索中使用技术名称可能会导致严重的歧义。

数据仓库匹配结果。与人口普查数据类似，其余37个未匹配的数据包（占比不足5%）已被排除在分析之外，因为这些数据包已从GitHub上删除。

GHTorrent数据库。为获取OSS价值创造的分散度指标，我们采用了GHTorrent数据库——该数据库通过GitHub的表征状态传输（REST）应用程序编程接口（API）收录了GitHub上的全部活动历史记录。我们利用其存储的GitHub仓库信息、开发者提交记录及开发者公开资料来评估每位开发者的贡献度。在开发者贡献度分析中，我们通过两步缩小样本范围：首先，根据我们联合Census-BuiltWith样本中的仓库URL，从GHTorrent中筛选出相应的GitHub仓库及其提交记录[10]；其次，通过剔除约8000名（占12%）被认定为机器人的GitHub贡献者，聚焦于人类对OSS的实际贡献[11]。最终样本包含约6万名开发者及230万次提交记录。

为了准备这三个数据集用于估算，我们首先使用开源软件包 pygount（用于统计代码行数）和 linguist（用于识别编程语言）来确定每个软件包的代码行数及所使用的编程语言。[12]我们将每种编程语言划分为三个不同的类别，从更可能由人类编写到更可能由机器编写（见表 A1）。类别 1 包含编程语言和标记语言（最可能由人类编写），类别 3 包含数据（最可能由机器编写），类别 2 则涵盖介于两者之间的内容，例如配置文件和批处理程序（这些内容有时由人类编写，有时由机器编写，但仅凭代码难以判断）。[13]在主要估算中，我们仅使用类别 1；对于类别 2 和 3，我们在附录中进行了稳健性验证，因此我们的结果代表了一个下限。最后，在某些分析中，我们进行了更深入的研究，展示了排名前五的编程语言（数据来源为 GitHub 2020 年发布的 2020 年数据）。排名前五的编程语言包括 C（含 C# 和 C++）、Java 和 JavaScript。

---

[10] 匹配率超过96%，未匹配的代码库仅占我们下文计算得出的开源软件（OSS）需求价值的0.15%。

[11] 该过滤机制基于GHTorrent对“虚假用户”的分类标准，同时还会识别包含“bot”或“robot”等关键词且被特殊字符包围的用户名。相较于GitHub创新图谱（https://innovationgraph.github.com/）等采用月度提交频率阈值进行机器人检测的方法，此方案更为保守。

[12] https://pypi.org/project/pygount/ 和 https://github.com/github-linguist/linguist

[13] 需要注意的是，我们的关注点在于重新编写由人类而非机器人编写的开源软件（OSS）代码所产生的成本。然而，在此情况下直接从机器人账户中移除所有开源贡献是不可行的，因为我们无法在GitHub上准确识别出这些机器人账户所编写的代码行。

Python 和 TypeScript。我们还将 Go 加入了这一顶级编程语言列表，因为 Go 在开源软件（OSS）领域正得到越来越广泛的应用。

3. 方法论

我们首先采用劳动力市场方法，从OSS的供给端和需求端两个维度来衡量其价值。[14]该理论假设是：我们所处的世界中并不存在OSS，每家企业在使用特定OSS时都需要重新创造该技术。通过劳动力市场方法，我们计算出每个OSS方案的劳动力替代成本。为估算各方案的价值，我们首先在单个方案层面应用 COCOMO II模型（Boehm，1984； Boehm 等，2009），随后汇总所有方案的价值以得出供给端的劳动力市场替代价值。接着，我们将供给端价值除以各企业使用每个方案的次数，并剔除企业内部的重复使用情况，从而得出需求端价值。

其次，我们超越总体层面，深入剖析价值创造过程中的不平等现象。在开源软件（OSS）领域，与许多创意项目类似，通常只有少数人贡献了大部分工作量，而其他人则做出较小贡献（这一现象被称为“80/20法则”，即80%的工作由20%的人完成）。研究表明，这些高频贡献者往往因其努力而在OSS社区中获得重要影响力（Hanisch等人，2018）。因此，为了更好地理解开发者在价值创造中的贡献分布情况，我们首先利用GHTorrent数据，通过两种方式识别每位开发者的贡献：a）直接评估其对OSS的价值贡献；b）统计其参与贡献的仓库总数。随后，我们检验这两种贡献衡量指标的集中程度，以明确究竟是大量还是少数开发者贡献了我们所衡量的总价值。下文将详细阐述劳动力市场分析方法及估值不平等的具体细节。

3.1 劳动力市场方法

在劳动力市场方法中，我们通过计算一个软件包的替代价值来估算开源软件（OSS）的价值。我们想了解，若雇佣一名程序员并支付其具有市场竞争力的薪酬来复制该软件包，需要花费多少成本。为了估算这一供给侧价值（即劳动力！），我们首先汇总上述所有开源软件包的完整列表，然后统计每个独特软件包中的代码行数。

[14] 在另一种版本中，我们采用了劳动力市场与商品市场相结合的方法，该方法更贴近 Greenstein 和 Nagle（2014）以及Murciano-Goroff等人（2021）的研究框架。然而，由于数据限制，将此方法应用于我们的研

究情境需要做出诸多额外假设。为简化表述，我们将其称为“商品市场方法”，相关细节、统计数据及局限性均列于附录A。

数据包。[15]对于每个独特的数据包i，我们先计算其价值，然后对所有这些价值求和以获得总价值：

$$V_S^{Labor} = \sum_{i=1}^{N} V_{S_i} = \sum_{i=1}^{N} P_i * 1 \,. \tag{1}$$

在本计算中，我们隐含地未纳入任何生产外部性，因为我们假设不同软件包之间不存在会降低编程成本的知识溢出效应。[16]该方法与其他估算开源软件（OSS）供给侧成本的研究方法相似（Blind 等人，2021； Nagle ，2019b； Robbins 等人，2021）。
随后，我们通过整合每个套餐的使用信息（Q），计算出OSS的需求侧价值：

$$V_D^{Labor} = \sum_{i=1}^{N} V_{D_i} = \sum_{i=1}^{N} P_i * Q_i \,. \tag{2}$$

在此，我们未纳入消费外部性因素，即当某个软件包被创建时，我们不允许普通公众从中获得任何收益；同时我们进一步确保每家企业仅替换其自身使用过一次的软件包，因为被替换的软件包可在企业内部作为俱乐部商品使用（例如参见 Cornes 和 Sandler，1996）。数值$V_S{}^{Labor}$反映了重新编写所有广泛使用的开源软件一次所需的成本（例如：OSS的概念仍然存在，但所有这些软件包都需要从头开始重写；而VLab%这一数值反映了每家使用这些OSS软件包的企业为聘请开发者重写这些软件包所支付的成本（例如，OSS本身已不复存在）。

对于供给和需求模型，我们均通过构建式成本模型II（简称 COCOMO II，Boehm 1984，Boehm et al. 2009）计算出每个软件包（pi）的美元价值。该模型此前已被美国国防部用于估算软件项目成本，并在多项研究中用于评估开源软件的价值（Blind et al.，2021； Nagle ，2019b； Robbins et al.，2021）。该模型具有高度灵活性，可实现代码行向美元价值的非线性转换，其建模方程如下：

[15] 我们仅使用纯代码行，排除了文档注释行和空行。因此，我们低估了重新编写每个软件包的真实价值。
[16] 类似于代表性代理模型（例如：（参见 Williamson 2006）），人们可以认为每个软件包都是由不同的程序员开发的，这些程序员彼此完全相同（因此技能水平相同，但不会通过学习而提高效率）。

$$E_i = \alpha \eta L_{,i} \quad (3)$$

其中L代表代码行数（单位：千行），E代表每个项目i的人力投入（单位：人月）。与 Blind 等人（2021）的研究一致，我们采用 α 、β 和 η 的默认参数值。参数 α 和 β 分别为非线性调整因子，设定值为2.94和1.0997；参数 η 是人力投入调整因子，可根据对产品、硬件、人员及项目特性的主观评估进行调整。由于缺乏各项目的先验信息，我们将 η 设为默认值1。为计算每个开源软件项目的价格（pi），我们将公式(3)的计算结果乘以程序员在公开市场上获得的加权全球平均薪资。全球平均薪资的计算参考了《Salary Expert》报告中2021年GitHub开发者数量排名前30个国家的软件开发人员基础月薪数据（Wachs 等人，2022）。[17]各国权重为其活跃GitHub贡献者数量占该国总贡献者总数的比例。我们进一步利用低工资水平（印度）和高工资水平（美国）的劳动力市场来设定工资范围，以便更准确地理解：在重构整个开源软件（OSS）的过程中，所使用的程序员群体不同会导致价值产生何种差异。[18]

3.2 贡献度衡量

为了更深入地理解价值是如何被创造的，以及这种创造是否均衡或不均衡，我们分三个步骤构建了可视化图表。第一步，我们衡量了开发者对价值的贡献；第二步，我们统计了开发者参与贡献的代码仓库数量；最后，我们运用广为人知的洛伦兹曲线概念，对这两项数据进行了可视化呈现，以便更清晰地了解贡献不平等的程度。具体细节如下所述。

价值贡献。我们计算了每位开发者对开源软件（OSS）所做出的供需价值贡献。在仓库层面，我们通过计算每位开发者提交的代码量占仓库总提交量的比例，量化了其工作贡献比例。随后，将该比例分别与仓库的需求价值和供给价值相乘，从而得出具体数值。

[17] Wachs等人研究中涵盖了179个县。（2022年），但排名前30的国家占据了全球活跃贡献者的88%以上，其余各国的占比均低于0.6%。前30个国家列于表A2中。

[18] 我们选择高薪和低薪参考国家时，综合考虑了GitHub活跃开发者数量与软件开发者群体的平均年薪水平。

该独立贡献者对代码库的增值贡献。最后，我们汇总每位开发者在所有代码库中的价值贡献。来自唯一开发者Dev、V_j^{Dev}的个体价值贡献可表示为：

$$V_j^{开发} = \sum_{Ni} \sigma_i^{开发} * V_{ij} \tag{7}$$

其中 σ_i^{Dev}表示核心开发者在仓库i中提交的代码占比；V_{ij}是公式(1)和(2)中定义的整个仓库i的需求或供给价值（其中 j ∈ {D，S}）；N表示我们主样本中的仓库数量，即 Census 和 BuiltWith 数据库的合并数量。

代码库贡献量。该数值表示特定开发者所贡献的代码库数量，具体计算方式如下：

$$N^{Dev} = \sum_i^N \mathbb{1}\{\sigma_i^{Dev} > 0\} \tag{8}$$

其中1表示指示函数，当开发者向仓库i提交的代码数量不为零时，该函数值为1。该指标反映了各开发者所承担的开源软件需求多样性。结合价值贡献度指标，这些数据有助于我们判断整体产生的价值是否集中在少数开发者手中。从开源软件生态系统的整体利益及其多样性角度来看，理想的情况是每位开发者都能参与多个代码仓库，而不仅仅是少数几个。

测量贡献值的离散度。为直观分析开发者贡献值的离散程度，我们采用了洛伦兹曲线（Lorenz，1905），分别针对需求侧和供给侧数值进行展示。洛伦兹曲线是表征不平等现象的成熟方法，因此能帮助我们更清晰地理解私营经济中开发者对开源软件贡献的离散程度。如公式(7)所示，开发者根据其对开源软件需求和供给的贡献值被系统地按升序排列。随后，这些排名被标准化为0至100百分位数的范围，作为洛伦兹曲线的横坐标；纵坐标则呈现相应的贡献值V_j^{Dev}。结果部分中的图表将清晰展示开发者在价值贡献方面的不平等程度。为补充分析，我们

为进一步探究代码仓库贡献度“Dev”的分布情况，我们绘制了方程(8)。这使我们能够确定：显著的价值不平等现象究竟是源于顶级贡献者主要专注于极受欢迎的少数代码仓库，还是源于他们参与了更多样化的成功代码仓库。

4. 结果

通过应用 COCOMO II的劳动力市场方法，我们获得了开源软件（OSS）价值的全球估算数据。计算总体价值时，首先需要基础代码行数（用于计算供给端价值），随后需获取使用统计数据（用于计算需求端价值）。鉴于不同编程语言的价值可能存在显著差异，如上所述，我们还列出了2020年调查期间使用最广泛的编程语言。

--- 表1如下 ---

表1分别展示了两个数据集的描述性统计结果。面向内核的Census代码库（图A）包含超过2.617亿行代码，其中72%的代码由主流编程语言编写。平均而言，每个软件包包含14.2万行代码；而在顶级编程语言构成的子集中，平均代码量略低，为11.3万行。从使用频率来看，Census软件包的使用次数超过270万次，其中92%的使用量来自顶级编程语言；而平均软件包的使用次数为1,472.4次，顶级语言的使用量更高，达到约1,497.5次。对于面向外部的BuiltWith数据，我们发现了相似的趋势，但具体比例有所不同：BuiltWith包含的软件包总代码量超过8,200万行，其中71%来自顶级编程语言；该样本中平均软件包包含11.1万行代码，而顶级语言的平均代码量较低，约为8万行。这是因为BuiltWith数据主要由基于JavaScript的软件包组成，这类软件包通常比其他语言编写的软件包更精简。BuiltWith软件包的总使用次数达14.2万次，其中99.97%的使用量来自顶级编程语言。接下来，我们利用这些原始观测数据，通过劳动力市场方法计算了所有OSS的价值，并估算了供需双方创造的价值。

--- 表2如下 ---

表2展示了基于企业相关的Census和BuiltWith联合样本对开源软件（OSS）价值的估算结果。表2中的所有估算数据均仅基于表A1中归入第一类的软件语言——这类语言最有可能由人类而非机器编写。[19]第一列分别列出了采用低收入国家（印度）工资水平、全球平均工资水平以及高收入国家（美国）工资水平的估算结果（如前所述）。若要使用印度开发者平均工资水平来重新开发所有广泛使用的开源软件（即：OSS的概念依然存在，但需删除当前所有代码并从头开始编码），所需投资为12.2亿美元；相比之下，若采用美国开发者平均工资水平，则需62.2亿美元才能完成相同工作。而采用基于上述地理分布对开源软件贡献度加权的全球程序员资源池时，所需投资金额将介于高低收入国家之间，约为41.5亿美元。将这些数据与同类研究结果进行对比有助于理解对所有开源软件（OSS）（先前研究）与广泛使用的开源软件（本研究）价值评估的差异。 Robbins 等人（2021）和 Blind 等人（2021）采用与我们类似的方法，估算出2019年美国产生的OSS价值为380亿美元，2018年欧盟产生的OSS价值为10亿欧元。 Wachs 等人（2022）指出，约50%的OSS贡献来自美国和欧盟的合计贡献。综合来看，这些研究得出的全球OSS价值总额为780亿美元。因此，我们针对仅限于面向企业且广泛使用的OSS所提出的41.5亿美元供应侧价值中值，是一个可信的下限估计值；该数值凸显了在未考虑特定OSS包是否被广泛使用的情况下，对OSS整体供应侧价值的更高估算结果。这进一步表明，最广泛使用的OSS其供应侧价值约占所有OSS供应侧价值的5.5%。

表2的第二列包含了基于劳动力市场方法得出的需求侧估算结果。我们发现，如果企业必须重新开发其使用的所有OSS软件包（例如.....）由于开源软件（OSS）本身已不复存在，所有使用其软件包的企业都需重新开发；因此，仅使用低工资国家或高工资国家的劳动力，相关总成本将分别介于2.59万亿美元至13.18万亿美元之间。而由全球程序员组成的团队只需约8.80万亿美元即可重新开发所有广泛使用的开源软件。解读这一数字的意义在于.....

[19] 附录中的表格展示了当包含软件语言分类桶1和2（表A3）以及全部三个软件语言分类桶（表A4）时，表2中的等效数值。

虽然略显复杂，但仍具有可行性。根据Statista（2023年）的报告，2020年（与我们的数据年份相同）全球软件收入为5317亿美元。然而，这代表的是软件的流量而非存量。基于政府估算——软件在三年内完全折旧——我们可以进行粗略计算：将2020年使用的全部预装软件采购价值视为2018至2020年间销售总额（1.54万亿美元）。此外，该数据仅涵盖预装软件的支出，不包括定制采购或内部开发的软件。关于私营部门软件总体投资的最佳估算数据来自美国国民收入与生产账户（NIPA 2023）。2020年国民账户数据显示，美国私营企业软件支出达4792亿美元，其中45%（2155亿美元）为预装软件。若假设全球其他地区也采用相同比例，则2020年企业用于软件的实际支出总额为3.4万亿美元（= 1.54万亿美元/0.45）。将这一粗略估算与基于全球平均工资（8.8万亿美元）得出的开源软件价值需求侧估算相结合，表明企业若需聘请内部开发者免费编写当前使用的开源软件，将支出12.2万亿美元（=3.4万亿美元 + 8.8万亿美元），相当于其当前支出的三倍半。

--- 图1 此处 ---

图1展示了主要编程语言中开源软件（OSS）价值的差异性。图A呈现了供应端价值，其中劳动价值以纵轴显示。研究发现，用Go语言开发的OSS包价值最高，达8.03亿美元——若这些OSS包不存在，就需要从零开始开发才能获得同等价值。紧随其后的是JavaScript和Java，价值分别为7.58亿美元和6.58亿美元。C和 TypeScript的价值分别为4.06亿美元和3.17亿美元，而Python在主要语言中价值最低，约为5500万美元。JavaScript不仅是自2014年以来GitHub上的主导语言（GitHub，2022），也是我们数据中价值最高的语言之一。相比之下，Python随着时间的推移日益流行，从第四位跃升至2020年GitHub上所有开源软件包中使用的第二大语言，尽管它在我们的主流语言排行榜中位列末位。

图B展示了主要编程语言在需求端的价值表现。根据实际使用产生的价值计算，Go语言的价值是紧随其后的JavaScript语言的四倍以上。

TypeScript（一种基于JavaScript扩展的语言）发展势头迅猛，从2017年全球十大编程语言中的第十位跃升至2020年的第四位；这一趋势在我们的数据中也得到印证——TypeScript已成为需求侧第三重要的编程语言。紧随这两种Web语言之后的是C语言，而Java和Python则远远落后。

--- 图2 正位于此处 ---

图2根据我们的内向数据源（Census）和外向数据源（BuiltWith）分别展示了各语言的OSS价值估算结果。图A和图B重点分析了Census数据中的供需侧估算情况。尽管JavaScript的影响显著较低，但其呈现的模式与整合两种数据源后的总体趋势（图1）基本一致。在图A所示的Census数据供给侧中，Java的价值排名第二，而Census数据中的JavaScript代码对整体价值的贡献明显较低。同样地，C、Python和 TypeScript在供给侧的价值主要由Census数据所驱动。从需求侧B组数据可以看出，Go是面向外部接口代码最常用的语言，而其他所有语言在相对使用量上均可忽略不计。

图2的C面板和D面板展示了BuiltWith数据集的供需侧数值。C面板中的供给侧数值清晰表明，BuiltWith样本中的价值主要来源于JavaScript代码——这一结果具有良好的合理性验证意义，因为正如前文所述，我们在该样本中以JavaScript包作为开源软件（OSS）的替代指标。第二高的数值由TypeScript产生，这令人安心，因为TypeScript是JavaScript的超集。D面板在使用侧呈现出相似模式：大部分价值仍来自JavaScript，而TypeScript则位列第二。其他编程语言对供需侧数值的贡献微乎其微。总体而言，这些发现与各类语言的主要应用场景（网页编程与应用编程）基本一致，也印证了“产生价值的语言未必与大众使用的语言相同”的观点。

--- 图3 如图所示 ---

图3展示了基于BuiltWith在线数据，按 NAICS 两位数代码划分的各行业软件服务外包（OSS）需求侧价值。[20]这一数值可解读为各行业因OSS的存在而获得的价值。使用价值最高的行业是“专业、科学和技术服务”，约为430亿美元；“零售贸易”以及“行政与支持服务、废物管理和修复服务”分别贡献了360亿美元和350亿美元，共同构成了OSS需求侧对外部价值的重要组成部分。相比之下，“采矿、采石及油气开采”、“公用事业”以及“农业、林业、渔业和狩猎”等行业的贡献占比较小。后三类行业属于典型的非服务业，因此软件在这些领域的应用价值相对有限。

——此处的图4——

图3展示了洛伦兹曲线，以及部分程序员为供应方（图A）和需求方（图B）贡献的代码库数量。如果洛伦兹曲线直接位于45度线上，就意味着程序员的价值分布极为均匀。然而，图A显示的洛伦兹曲线几乎呈直线状，且程序员中最后那部分人的贡献比例急剧上升。这表明供给端价值的分布极不均衡，其集中度远超80/20法则的标准。事实上，最后5%的程序员（即3000人）贡献了超过93%的供给端价值；同样地，图B在考虑使用量后显示，这最后5%的程序员贡献了超过96%的需求端价值。总体而言，这表明极少数程序员创造了企业用于编写自身代码的大部分开源软件代码。在图A和图B中，我们还可以看到为贡献最高价值的最后10%-15%程序员所维护的代码库数量有所增加——这表明少数程序员产生的不均衡价值并非仅源于几个高价值代码库，而是源于这少数贡献者对大量代码库的贡献。

5. 结论

[20] 由于人口普查数据包含客户的专有信息，因此未能完整呈现整个数据集中的各行业分布；因此，我们只能利用BuiltWith提供的公开数据来展示各行业的数值分布。我们通过将BuiltWith网站与Orbis和Compustat数据集中的行业信息进行匹配，实现了这一目标。通过该流程，94.6%的BuiltWith网站成功匹配到了所属行业。对于涉及多个行业的企业（域名），我们取其数值平均值并按行业进行分布展示。

在本研究中，我们利用两个独特的数据集——OSS人口普查数据和BuiltWith数据——对全球广泛使用的开源软件价值进行了评估。我们不仅能够估算现有代码的供给端价值（例如，重新编写每个广泛使用的开源软件代码所需的成本），还能估算私营经济的需求端价值（例如，每家使用某开源软件的公司重新编写该软件所需的成本）。尽管我们并未重点关注开源软件的“长尾”部分，但这正是本研究的另一贡献：聚焦于广泛使用的开源软件，使我们能够更精确地理解其创造的价值，而非仅计算所有开源软件的替换成本（后者会高估真实价值，因为许多开源项目并未实际用于生产代码）。然而，尽管我们基于大量使用数据强调了开源软件在社会中的巨大价值，但要全面识别全球范围内使用的全部开源软件并不现实；因此，我们的需求端估值很可能低估了其真实价值。

经使用量调整后，我们发现OSS的需求侧价值高达8美元。当使用来自全球各地的程序员时，总价值达到8万亿美元（具体数值略有波动，取决于我们仅从低收入国家还是高收入国家招聘程序员）。不同编程语言的价值存在显著差异；代码是面向内部使用（即用于开发待销售的产品）还是面向外部使用（即用于公司网站）也会影响价值。排名前六的编程语言贡献了84%的需求端价值。此外，不同行业之间也存在显著差异；最后，程序员自身对价值的贡献程度也各不相同：超过95%的需求端价值仅由5%的程序员创造，而这些程序员不仅参与了少数几个广泛使用的项目，其参与的项目数量远超过那些处于价值分布低端的程序员。

总体而言，我们的研究结果表明，开源软件（OSS）对经济具有显著价值；尽管通过直接测量，这一价值通常显示为零——因为其价格为零，且仅凭公开数据难以准确衡量其数量。我们的研究为未来不仅针对开源软件（OSS），而且针对整个信息技术（IT）及其对全球经济日益增长的影响的研究奠定了基础。

参考文献

Almeida，D. A. 、 Murphy，G. C. 、 Wilson，G. 和 Hoye，M.（2017年5月）。软件开发者是否理解开源许可证？收录于2017年IEEE/ACM第25届国际程序理解会议（IC-PC）论文集（第1–11页）。IEEE。

Andreessen, M. (2011).《为何软件正在改变世界》.访问日期:2023年5月1日.来源:https://www.wsj.com/articles/SB10001424053111903480904576512250915629460

亚里士多德。（1981）。《政治学》第二卷第三章。T·A·辛克莱译。企鹅出版社，伦敦。

Blind，K. 、 Bohm，M. 、 Grzegorzewska，P. 、 Katz，A. 、 Muto，S. 、 Patsch，S. 和 Schubert，T.（2021）。开源软件与硬件对欧盟经济技术独立性、竞争力及创新能力的影响。欧盟委员会编。

Blind, K., & Schubert, T.(2023).估算开源软件对GDP的影响及其与研发和专利的互补性:证据与政策启示.《技术转移杂志》,第1–26页.

Boehm, B. W. (1984).《软件工程经济学》.《IEEE软件工程汇刊》,第1卷,第4–21页.

Boehm，B. W.，Abts，C.，Brown，A. W.，Chulani，S.，Clark，B. K.，Horowitz，E.，Madachy，R.，Reifer，D.，& Steece，B. (2009).《 COCOMO 软件成本估算》第二版。普伦蒂斯霍尔出版社。

Branstetter、Lee G.、 Matej Drev 和 Namho Kwon .（2019）。“与时俱进：传统制造业中的软件驱动创新。”《管理科学》第65卷第2期：541–558页。

Brynjolfsson, E. (1993).信息技术的生产率悖论.《ACM通讯》,36(12),66–77.

Brynjolfsson, E., & Hitt, L.(1996).悖论消失了吗?关于信息系统支出回报的公司层面证据.《管理科学》,42(4),541–558.

Brynjolfsson, E., Rock, D., & Syverson, C. (2018).人工智能与现代生产率悖论:期望值与统计数据的冲突.载于《人工智能经济学》.

《情报：一项议程》（第23–57页）。芝加哥大学出版社。

Burton，R. M.，Hakonsson，D. D.，Nickerson，J.，Puranam，P.，Workiewicz，M.，& Zenger，T.

(2017) GitHub：探索无领导型与层级化组织形式之间的过渡空间。*《组织设计杂志》*，*6*，1–19。

Conti，A. 、 Peukert，C. 与 Roche，M.（2023）：“为投资者提升IT实力？开源与初创企业融资：基于GitHub的实证研究。”“*哈佛商学院工作论文第22-001号*。

Cornes, R., & Sandler, T. (1996).外部性理论, 公共物品与俱乐部物品.

剑桥大学出版社

DeStefano，T. 与J. Timmis（2023）。《需求冲击与数据分析扩散》，工作论文。

Dushnitsky, G., & Stroube, B. K. (2021).低代码创业:Shopify与增长的另一种路径.《商业风险投资洞察期刊》,第16卷,e00251.

Eisfeldt, A. L., & Papanikolaou, D. (2014).无形资本的价值与所有权.

《美国经济评论》，第104卷第5期，第189–194页。

欧盟委员会。（2020）。《2020–2023年开源软件战略》。卢森堡：欧洲共同体官方出版物办公室。

第14028号行政命令。（2021年）《关于加强国家网络安全的行政命令》。
2021年5月。

Fackler，T.、 Hofmann，M. 和 Laurentsyeva，N.（2023）。*挑战重力：是什么推动了远程团队的生产力？*（第427期）。CRC TRR 190：理性与竞争。格林斯坦（S. Greenstein）与纳格尔（F. Nagle），2014年。《数字暗物质与Apache系统的经济贡献》。*《研究政策》，第43卷（第*4期），第623–631页。

GitHub（2022）。"Octoverse：开源软件现状。"检索于2023年11月3日。https://octoverse.github.com/2022/top-programming-languages。

Hanisch, M., Haeussler, C., Berreiter, S., & Apel, S.(2018年7月).开发者在Linux内核开发项目中从边缘角色晋升为核心成员.载于《*管理学院学报*》(2018年第1卷第1期,第14263页).纽约州布赖尔克利夫庄园10510:管理学院.

Hardin，G. (1968). 《公地悲剧》. 《科学》. 162(3859): 1243–1248.

Henkel, J. (2信息源).《信息披露的倡导者——开源开发者在商业企业中的作用》.《工业与企业变革》,18(3),435–471.

Jacks, J. (2022).开源软件对软件产业的冲击速度,已超过软件对整个世界的冲击速度.访问日期:2023年5月1日.来源:https://www.coss社区/开源社区eating-software-faster-than-software-is-eating-the-world-3b01

Kim, D. Y. (2020).产品市场绩效与开放性:客户异质性的调节作用.载于《*管理学院学报*》(2020年第2020卷第1期,第21309页).纽约州布赖尔克利夫庄园10510:管理学院.

Koning，R.、 Hasan，S. 与 Chatterji，A.（2022）。实验设计与初创企业绩效：A/B测试的证据。《管理科学》，68(9)，6434-6453。

Krishnan, M. S., Kriebel, C. H., Kekre, S., & Mukhopadhyay, T. (2000).软件产品生产率与质量的实证分析.《管理科学》,46(6),745–759.

Lerner, J., & Tirole, J.(2005).开源许可的范围.《法律, 经济学与组织学杂志》,21(1),20–56.

Lorenz，M. O.（1905）。《衡量财富浓度的方法》。《美国统计协会出版物》。第*9卷*，第70期。第9卷（总第70期）：209–219页。文献代码：1905PAmSA...9..209L。doi：10.2307/2276207。 JSTOR：2276207。

Lifshitz-Assaf, H., & Nagle, F. (2021).数字经济以开源为基础运行.以下是保护它的方法。《哈佛商业评论》数字文章。https://hbr.org/2021/09/the-digital economy-runs-on-open-source-heres-how-to-protect-it。

Lloyd, W. F. (1833).关于人口控制的两场演讲:于1832年迈克尔马斯学期在牛津大学发表.作者:JH Parker.

Maracke, C. (2019).自由及开源软件与基于 FRAND 的专利许可:如何在标准必要专利与自由及开源软件之间寻求平衡.《世界知识产权杂志》,22(3-4),78-102.

Murciano-Goroff, R., Zhuo, R., & Greenstein, S. (2021). 隐性软件与隐性价值创造:服务器软件使用案例分析.*Research Policy*,*50*(9),104333.

Musseau，J.、 Meyers，J. S.、 Sieniawski，G. P.、 Thompson，C. A. 和 German，D.（2022年5月）。开源软件是否正在吞噬全球软件市场？利用Java二进制文件测量专有软件中开源软件的比例。收录于*第19届国际软件代码库挖掘会议论文集*（*第561–565*

页）。
纳格尔，F.（2018）。通过贡献学习：通过为众包公共产品做出贡献获得竞争优势。《组织科学》，29(4)，569–587。

Nagle，F. (2019a). 开源软件与企业生产率. 《管理科学》，65(3)，1191–1215。

Nagle，Frank (2019b). 《政府技术政策、社会价值与国家竞争力》. 哈佛商学院工作论文，第19-103号，2019年3月。

Nagle，F.，Dana，J.，Hoffman，J.，Randazzo，S.，& Zhou，Y. (2022). 自由及开源软件第二次普查——应用库。*Linux基金会、哈佛创新科学实验室（LISH）与开源安全基金会（OpenSSF）。https://www.linuxfoundation.org/research/census-ii-of-free-and-open-source-software应用库。*

NIPA（2023）。经济分析局，NIPA表5.6.5。访问日期：2023年11月14日，来源：https://apps.bea.gov/iTable/？reqid=19&step=3&isuri=1&select_all_years=0&nipa_table_list=331&series=q&first_year=2013&last_year=2023&scale=-9。

威廉·D·诺德豪斯，2006年，《Nonmarket Acco 单位的 National Accounting 原则》，载于*《美国国民账户的新架构》*（戴尔·W·约根森、J·史蒂文·兰德菲尔德与威廉·D·诺德豪斯主编），芝加哥大学出版社。

奥斯特罗姆，埃莉诺（1990）。治理公共资源：集体行动制度的演进。剑桥：剑桥大学出版社。

Peters, R. H., & Taylor, L. A. (2017).无形资本与投资-收益关系.《金融经济学杂志》,123(2), 251–272.

Robbins，C.、Korkmaz，G.、Guci，L.、Calderon，J. B. S. 与 Kramer，B.（2021）。《美国及其他国家开源软件投资现状初探（2009–2019年）》。

Singh，Shivendu Pratap (2020)*《产品、平台与开放式创新：三篇关于技术创新的论文》*。匹兹堡大学博士论文（未出版）

Solow，R. (1987). "我们最好当心。" *《纽约时报书评》*，1987年7月，第36页。

Statista（2023）。Statista Software Worldwide，访问日期：2023年11月14日，来源：https://www.statista.com/outlook/tmo/software/worldwide#revenue，访问时间：2023年11月。

Synopsys（2023）。《2023 OSSRA：开源趋势深度解析》。访问日期：2023年5月1日。来源：https://www.synopsys.com/blogs/software-security/open-source-trends-ossra 报告/

Tang，S.、Wang，Z. 和 Tong，T.（2023）。开源贡献中的知识治理：守门人的角色。载于*《管理学院学报》*（2023年第2023卷第1期，第17622页）。纽约州布赖尔克利夫庄园，邮编10510：管理学院。

Tozzi，C. (2016). 《开源历史：Linux为何成功？》*Channel Futures*，2016年8月。访问日期：2023年11月3日。https://www.channelfutures.com/open-source/open source-history-why-did-linux-succeed

Wachs, J., Nitecki, M., Schueller, W., & Polleres, A.(2022).开源软件的地理分布:来自GitHub的证据.*技术预测与社会变革*,*176*,121478.

Williamson, S. (2006).《宏观经济理论札记》.圣路易斯大学经济系.

Zhang, Y., Zhou, M., Mockus, A., & Jin, Z.(2019).企业参与OpenStack开发——一项关于OpenStack的实证研究.《IEEE软件工程汇刊》,47(10),2242–2259.

图1开源软件的价值：主流编程语言

A组：供应方

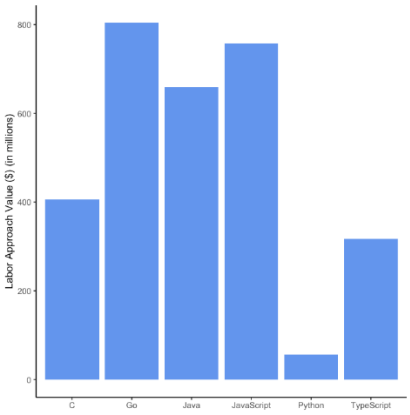

B面板：需求侧

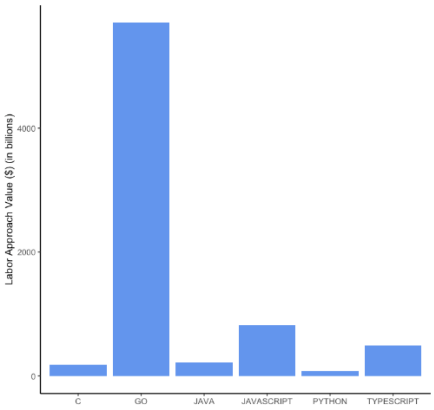

注。图表展示了根据GitHub及Go语言统计的前五大编程语言的劳动力市场价值。图A呈现供给端数据，图B则包含使用量数据。在劳动力方面，我们采用了方法论部分所述的全球程序员平均工资估算值。

图2：前五大编程语言（含Go）及各类数据源中的开源价值

A组：人口普查。供给方面

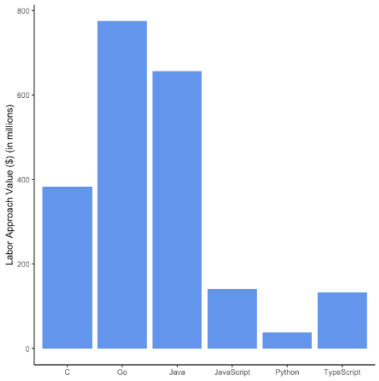

B面板：人口普查。需求侧

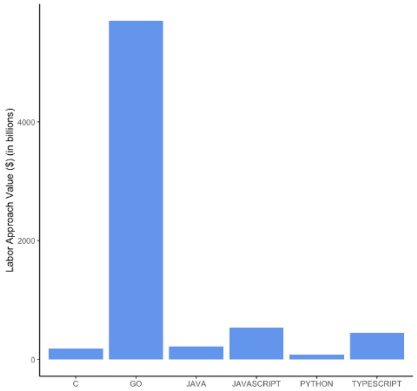

C面板：BuiltWith。供给侧

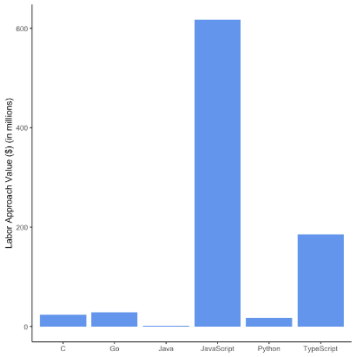

D面板：BuiltWith。需求侧

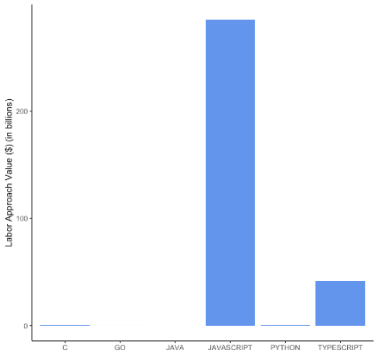

注：图表展示了排名前五的语言（根据 GitHub 数据）及 Go 语言的劳动力与商品市场价值，并按数据来源分为面向内向（Census）和面向外向（BuiltWith）两类。图 A 和图 B 分别展示了 Census 数据的供给侧与需求侧数值；图 C 和图 D 则展示了 BuiltWith 数据的供给侧与需求侧数值。

图3网站各行业开源价值

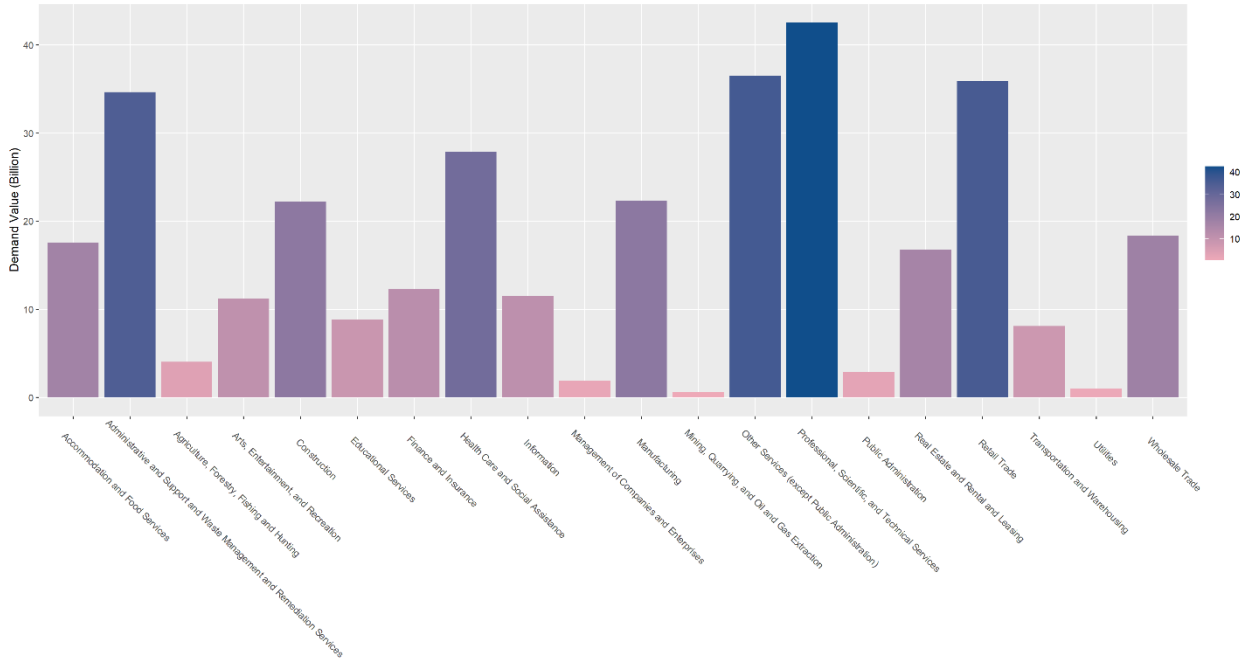

注。该图展示了基于Built With数据、涵盖 NAICS 两位代码行业的需求侧劳动力价值。对于涉及多个行业的企业（领域），我们取其平均值并按行业进行分配。

图4开源价值创造的分布情况

A组：供应方

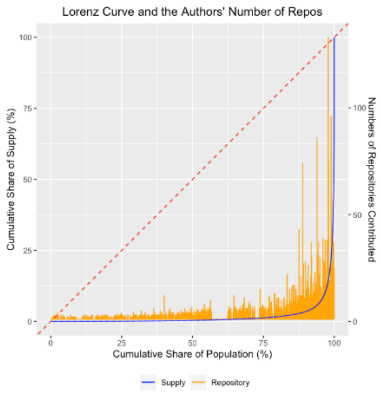

B面板：需求侧

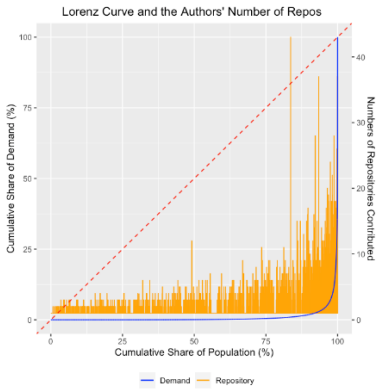

注。图表展示了每位开发者对劳动力市场价值的贡献（蓝色曲线）以及部分程序员所贡献的代码仓库数量（黄色曲线）。图A展示供给端情况，图B则反映了使用情况。

表1代码行数及使用情况的描述性统计

	总数	平均；平均值	SD	观察
A组：人口普查				
代码行数 – 所有软件包	261,653,728	142,203.1	887,937.2	1,840
代码语言排行榜：前五名语言及 Go 语言	189,673,184	113,712.9	702,832.1	1,668
使用说明 – 所有软件包	2,709,155	1472.4	2,167.9	1,840
使用情况——排名前五的语言及 Go 语言	2,497,785	1497.5	2,228.8	1,668
B组：BuiltWith				
代码行数 – 所有软件包	82,504,613	111,342.3	613,488.1	741
代码语言排行榜：前五名语言及 Go 语言	58,664,935	79,925.0	354,415.0	734
使用说明 – 所有软件包	142,794.4	192.7	733.4	741
使用情况——排名前五的语言及 Go 语言	142,751.2	194.5	736.6	734

注：这些统计数据基于不同代码库中的代码行。图A(B)展示了使用第1组所有软件包时，人口普查（BuiltWith）数据在不同代码行及使用场景下的总和、均值、标准差及观测值数量（详见表A1）。

表2开源的劳动力市场价值

	劳动力供应	劳动力需求
工资：较低	12.2亿美元	2.59万亿美元
工资：全球标准	41.5亿美元	8.80万亿美元；13.18万亿美元
工资：高	62.2亿美元	

注：高薪情景基于美国程序员的平均薪资，低薪情景则基于2020年印度程序员的平均薪资。全球薪资数据取自表A4所列各国的平均薪资，并根据其对开源软件（OSS）的贡献程度进行加权计算。这些估算仅包含归类于第1桶（bucket 1）的软件所支持的语言（详见表A1）。

在线附录

表 A1每个类别内的语言

类型	语言
A组：桶1 – 语言	
标记语言	BIBTEX
标记语言	COLDFUSION HTML
标记语言	DOCBOOK XML
标记语言	低增生性急性髓细胞性白血病
标记语言	HTML
标记语言	HXML
标记语言	JAVAEE XML
标记语言	标记语言
标记语言	梅森
标记语言	MXML
标记语言	RELAX-NG 紧凑型
标记语言	RHTML
标记语言	纹理
标记语言	可扩展标记语言
标记语言	XQUERY
标记语言	YAML
编程语言	ABNF
编程语言	ACTIONSCRIPT
编程语言	ADA
编程语言	APPLESCRIPT
编程语言	ARDUINO
编程语言	ASPECTJ
编程语言	ASPX-CS
编程语言	ASPX-VB
编程语言	AWK
编程语言	C
编程语言	C#
编程语言	CHARMCI
编程语言	CLOJURE
编程语言	COFFEESCRIPT
编程语言	通用 LISP
编程语言	CSS
编程语言	CUDA
编程语言	CYTHON
编程语言	D
编程语言	DART
编程语言	德尔菲
编程语言	EASYTRIEVE
编程语言	EC
编程语言	灵药；药水
编程语言	ELM
编程语言	EMACSLISP

编程语言	ERLANG
编程语言	F#
编程语言	鱼类；鱼类生物
编程语言	福斯
编程语言	FORTRAN
编程语言	FORTRANFIXED

编程	语言	差距；差距
编程	语言	格金
编程	语言	GLSL
编程	语言	走
编程	语言	GRAPHVIZ
编程	语言	GROOVY
编程	语言	HASKELL
编程	语言	HAXE
编程	语言	本地指令集
编程	语言	Java
编程	语言	JAVA 服务器页面
编程	语言	JAVASCRIPT
编程	语言	KOTLIN
编程	语言	LESSCSS
编程	语言	液体
编程	语言	LIVESCRIPT
编程	语言	LLVM
编程	语言	标志
编程	语言	LUA
编程	语言	MATHEMATICA
编程	语言	MINISCRIPT
编程	语言	MODULA-2
编程	语言	海军航空医学院
编程	语言	NIX
编程	语言	目标-C
编程	语言	目标-J
编程	语言	OCAML
编程	语言	OPENEDGE ABL
编程	语言	PAWN
编程	语言	珍珠
编程	语言	英文超文本预处理语言的缩写。是一种内嵌式的语言
编程	语言	PL/PGSQL
编程	语言	附言
编程	语言	POVRAY
编程	语言	序言
编程	语言	属性
编程	语言	木偶
编程	语言	几何体
编程	语言	REASONML
编程	语言	REBOL
编程	语言	REDCODE
编程	语言	REXX
编程	语言	RUBY
编程	语言	锈迹；腐蚀
编程	语言	S
编程	语言	SASS
编程	语言	比例尺
编程	语言	一种"开放源码"软件
编程	语言	SCSS
编程	语言	纤细型；苗条型
编程	语言	SMALLTALK
编程	语言	诚信；可靠
编程	语言	标准 ML
编程	语言	SWIFT

编程 语言 SWIG
编程 语言 TADS 3

编程	语言	TCL
编程	语言	蒂夫里特
编程	语言	TRANSACT-SQL
编程	语言	街顶
编程	语言	类型脚本
编程	语言	VB.NET
编程	语言	VBScript
编程	语言	VCL
编程	语言	VIML
编程	语言	Web IDL

B面板：桶2 – 辅助语言

转义符/编译器/解释器/宏	处理器	气体
转义符/编译器/解释器/宏	处理器	M4
转义符/编译器/解释器/宏	处理器	RAGEL 红宝石主持人
配置		CMAKE
配置		初始化设置文件的后缀名
配置		生成文件
配置		NGINX 配置文件
配置		非特异免疫抑制疗法
配置		SQUIDCONF
配置		特拉福姆
配置		TOML
格式		格罗夫
IDE		NETBEANS 项目
模板引擎		猎豹
模板引擎		GENSHI
模板引擎		PUG
模板引擎		聪明的
模板引擎		速度
终端/批次		ANT
终端/批次		APACHECONF
终端/批次		XSLX
终端/批次		BATCHFILE
终端/批次		女专家；女权威
终端/批次		POWERSHELL
终端/批次		RPMSPEC
终端/批次		奇点
终端/批次		TCSH
翻译的；转化的		GETTEXT 目录

C面板：桶3 – 数据

数据	BNF
数据	微分
数据	DTD
数据	电子邮件
数据	JSON
数据	协议缓冲区
数据	RESTRUCTUREDTEXT
数据	纯文本

表 A2全球工资最高的前 30 个国家

国家
美国、中国、德国、印度
英国
巴西
俄罗斯
法国
加拿大
日本
韩国
荷兰
西班牙
波兰
澳大利亚
瑞典
乌克兰
意大利
瑞士
印度尼西亚
台湾
哥伦比亚
阿根廷
墨西哥
挪威
比利时
丹麦

注：排名前30的国家按GitHub用户分享量升序排列，涵盖了2020年GitHub活动总量的88%。

表 A3使用第1和第2类别语言的开源在劳动力市场中的价值

	劳动力供应	劳动力需求
工资：较低	12.3亿美元	2.6万亿美元
工资：全球标准	41.8亿美元	8.84万亿美元；13.24万亿美元
工资：高	62.6亿美元	

注：高薪情景基于美国程序员的平均薪资，低薪情景则基于2020年印度程序员的平均薪资。全球薪资数据取自表A4所列国家的平均薪资水平。相关估算仅涵盖第1和第2组语言（详见表A1）。

表 A4使用第 1、2 和 3 组语言的开源在劳动力市场中的价值

	劳动力供应	劳动力需求
工资：较低	18.8亿美元	3.52万亿美元；11.96万亿美元
工资：全球标准	64.1亿美元	17.91万亿美元
工资：高	95.9亿美元	

注：高薪情景基于美国程序员的平均薪资，低薪情景则基于2020年印度程序员的平均薪资；全球薪资数据取自表A4所列国家的平均薪资水平。相关估算仅涵盖第1、2、3类编程语言（详见表A1）。

表 A5商品篮子——等效开源软件与专有软件

开源软件	专有软件
Apache HTTP服务器	Windows Server 2008
大胆；自信	Adobe Audition
掺和器	Autodesk Maya
Elasticsearch	亚马逊肯德拉
FileZilla	SmartFTP
免费CAD	著名的三维辅助设计软件
GIMP	Adobe Photoshop
GNU Octave	矩阵实验室
GnuCash	QuickBooks
KeePass	1Password
LibreOffice	Microsoft Office 套件
MariaDB服务器	Microsoft SQL Server
以基为起点	Tableau
MySQL	Oracle MySQL
OpenVPN	ExpressVPN
PSPP	SPSS
Redis	Redis 企业版
张量流	TensorFlow Enterprise
虚拟盒	虚拟机
VLC 媒体播放器	CyberLink PowerDVD

表 A6使用第 1、2 和 3 组语言的开源产品市场价值

	商品需求桶 1；商品需求桶 1-2；商品需求桶 1-3		
工资：较低	1.77亿美元	1.79亿美元	2.42亿美元
工资：全球标准	1.77亿美元	1.79亿美元	2.42亿美元
工资：高	1.77亿美元	1.79亿美元	2.42亿美元

注：高薪情景基于美国程序员的平均薪资，低薪情景则基于2020年印度程序员的平均薪资；全球薪资数据取自表A4所列国家的平均薪资水平。相关估算仅涵盖第1、2、3类编程语言（详见表A1）。

附录A）商品市场估值法

作为一种替代性估算方法，我们并未采用劳动力替代成本法，而是采用了商品替代价值法。我们筛选出若干具有类似闭源付费替代方案的开源软件包，并计算了若所有免费开源软件的商业用户都必须用付费替代方案替换这些软件时所需的成本（该计算方式类似于Greenstein 和 Nagle（2014）以及Murciano-Goroffet等人（2021）对网络服务器所做的测算）。随后，我们可以将这一替代性的p值与前述q值相结合，从而估算出开源软件的商品替代价值。该方法借鉴了Nordhaus（2006，第146页）的观点："……市场与非市场商品及服务的价格应基于可比的市场商品及服务进行推算。"我们预计这两种方法得出的估算结果不会相近。恰恰相反，由于后一种商品市场法假设商品售价固定且可多次出售，而该固定价格通常低于通过劳动力成本重新开发所有软件包所估算的总价值，因此两种方法得出的价值存在显著差异。这些估算值之间的差异，本质上是由于某家公司介入，重新开发了缺失的OSS软件包，并以一定价格出售，而非所有公司都必须自行从头开始重新开发这些软件包。

采用商品市场方法时，我们的思想实验仍然是：我们生活在一个开源软件（OSS）并不存在的世界中，但必须通过一家企业重新构建这种软件生态——该公司会对目前免费提供的产品收取费用。为了通过商品市场方法评估开源软件的价值，我们构建了一个由等效替代性专有产品组成的商品篮子，这些产品的定价基于公开市场数据，用以替代开源软件产品。该方法论与先前文献（Greenstein and Nagle，2014； Murciano-Goroffet al.，2021）所采用的方法一致，不过这两项研究仅使用单一产品而非商品篮子，因为它们仅聚焦于一种类型的开源软件（Web服务器）。由于目前缺乏现成的开源软件等效产品的数据库，我们根据对开源软件流行度的主观判断进行搜索，进而寻找相应的付费闭源替代品。最终形成的包含20个开源软件包及其专有替代品的集合，很好地体现了开源软件的多样性。这些软件涵盖媒体与设计软件、统计分析程序、数据库管理软件以及网络服务器软件等多个领域。[21]

[21] 表A5展示了我们使用的开源软件（OSS）及其专有软件对应产品的组合。在构建该组合时，我们筛选了那些拥有功能与特性集高度相似的OSS对应产品的专有软件，并力求找出能够综合反映各类OSS广泛且代表性特征的软件组合。

基于我们构建的开源软件等效替代专有软件商品篮子，我们获得了每种专有软件等效物的价格，并计算了篮子中每个开源软件产品的 COCOMO 劳动力市场供给侧价值——由于缺乏专有软件的代码，该数值被用作专有软件 COCOMO 劳动力供给侧价值的代理指标（例如，支付程序员从零开始编写该专有软件所需的成本）。随后，我们计算了该商品篮子的平均 COCOMO 劳动力供给侧价值$V_{S\ Basket}$，以及篮子的平均价格$P_{S\ Basket}$。[22]由于我们已知所有开源软件的劳动力市场供给侧价值$V_S{}^{Labor}$，可通过以下方程并借助简单的缩放变换，得出所有开源软件在商品市场上的价格P_S：

$$\frac{P_S}{V_S^{Labor}} = \frac{P_{S,Basket}}{V_{S,Basket}}$$

$$P_S = \frac{V_S^{Labor}}{V_{S,Basket}} P_{S,Basket} \tag{4}$$

由此得出以下商品市场供给侧价值：

$$V_S{}^{商品} = P_S * 1。 \tag{5}$$

随后，我们可以按以下方式得出等效的需求侧商品市场价值：

$$V_D^{Goods} = P_S * Q. \tag{6}$$

从商品市场角度而言，我们考虑的是：如果一家企业生产所有现有的广泛使用的开源软件（OSS），并将其作为产品销售给客户，其收取的等效价格。

表A6第3列显示，无论程序员的来源国如何，各收入区间的需求侧价值均介于1.77亿美元至2.44亿美元之间。显然，商品市场的价值远低于劳动力需求价值——因为这家虚拟企业只需一次生产软件并批量销售给客户，就能以相对较低的价格实现盈利。此外，尽管 Greenstein 和 Nagle（2014）以及 Murciano-Goroff 等人（2021）仅聚焦于某一类软件（Web服务器），我们试图将其研究方法扩展至多种商品。然而，在此背景下，数据限制成为更显著的制约因素，使得研究本身更为困难。

[22] 我们通过采用软件3年使用寿命（即1/(1-0.66)）计算了商品市场专有篮子的平均价格，因此折旧系数为0.33。这与美国国税局（IRS）关于软件折旧的规定一致，该规定指出：“如果能够对计算机软件的成本进行折旧，则应在36个月的使用年限内采用直线法进行折旧。” https://www.irs.gov/publications/p946#en_US_2022_publink1000107354。

通过这种方法来估算价值时，需要做出大量额外假设。与纯粹的商品市场方法不同，该方法需要借助劳动力市场方法来调整估算参数，这最终会导致对开源软件价值的严重低估。此外，专有软件对应产品的定价策略对市场需求极为敏感。当商品市场方法应用于多种产品时，其隐含的核心假设是：我们的软件产品组合与样本开源软件的市场需求相似，因此它们应具有相应的价格水平。

另一种更为简化的商品市场粗略估算方法（该方法不考虑代码行数，也不依赖劳动力市场方法中的规模效应）只需将参考商品的价格与使用量相乘即可。我们可以采用参考价格向量 p = (69.99,1610.17,5800) 中记录的专有商品篮子的最低价、均价和最高价，然后将其与来自综合人口普查数据和 BuiltWith 样本的使用量数据相乘（见表 1）。根据这些估算的专有价格假设，商品市场的需求侧价值范围将在0.2万亿美元至16.5万亿美元之间（最低价–最高价），平均价格对应的估值约为4.5万亿美元。然而，尽管这一估算方法比劳动力市场法产生的波动性略大，但其本身存在根本性缺陷——它简单地假设所有开源产品的估算价格均基于参考价格完全一致。我们进一步认为，这种粗略估算方法实属“以橙子比苹果”的类比：因为我们所研究的产品组合中的软件均为功能完备的独立软件包，而人口普查数据集和BuiltWith数据集中的软件包则由应用程序库组成，而这类库通常比独立软件包规模更小。

鉴于在采用商品市场法时因数据不足而必须做出诸多复杂假设，我们更侧重于正文重点阐述的劳动力成本法；但为确保内容完整，此处亦一并纳入该方法。